# Grupo de R Madrid (10/05/2018) Machine Learning Automatizado

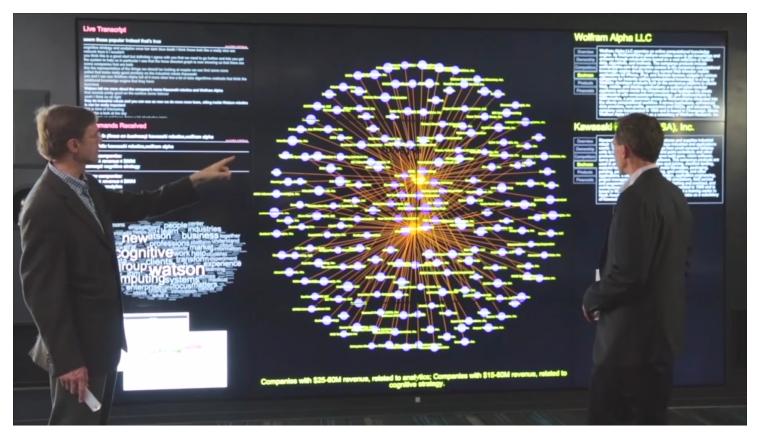


## Presentación

- Físico. MBA y Máster Bl y BigData
- Consultor Freelance
- Kaggle Máster
- Socio Asociación de Usuarios de R de España
- santiago\_mota@yahoo.es
- http://es.linkedin.com/in/santiagomota



# Dario Gil: Cognitive systems and the future of expertise TED (22/12/2014)





# IBM anuncia Watson Analytics, un servicio de analítica cognitiva de negocio (19/09/2014)

- "IBM Watson Analytics automatiza, además, algunos pasos del análisis, como la preparación de los datos, el análisis predictivo y la visualización... ".
- "Diálogo en lenguaje natural: el nuevo producto entiende el lenguaje natural, por lo que solo es necesario teclear lo que al usuario le gustaría ver...".
- "Analítica predictiva "guiada": el servicio es capaz de guiar al usuario en patrones y resultados de los datos en los que el usuario tradicionalmente no se fijaría".

# Gartner. Data Science y ML Platforms







# Tools that Data Scientists actually use



| id | superficie_sq_ft | tipo        | parcela_acres | habitaciones | banos | precio_venta |
|----|------------------|-------------|---------------|--------------|-------|--------------|
| 1  | 719              | Casa        | 1,64          | 1            | 1     | 88.000       |
| 2  | 2.017            | Apartamento | ,             | 3            | 2     | 164.000      |
| 3  | 697              | Apartamento |               | 1            | 1     | 72.000       |
| 4  | 948              | Casa        | 1,02          | 2            | 3     | 85.000       |
| 5  | 3.375            | Apartamento |               | 3            | 4     | 271.000      |
| 6  | 3.968            | Apartamento |               | 4            | 4     | 482.000      |
| 7  | 790              | Apartamento |               | 1            | 2     | 88.000       |
| 8  | 1.341            | Casa        | 0,66          | 3            | 3     | 128.000      |
| 9  | 2.379            | Apartamento |               | 3            | 3     | 235.000      |
| 10 | 2.495            | Casa        | 0,21          | 3            | 4     | 309.000      |
| 11 | 1.356            | Apartamento |               | 1            | 1     | 163.000      |
| 12 | 3.361            | Casa        | 1,64          | 3            | 4     | 375.000      |
| 13 | 1.060            | Casa        | 0,05          | 1            | 1     | 98.000       |
| 14 | 582              | Casa        | 0,61          | 1            | 1     | 50.000       |
| 15 | 1.640            | Apartamento |               | 2            | 3     | 145.000      |
| 16 | 3.546            | Casa        | 0,40          | 4            | 4     | 394.000      |
| 17 | 903              | Apartamento |               | 2            | 2     | 82.000       |
| 18 | 1.096            | Casa        | 0,40          | 3            | 4     | 105.000      |
| 19 | 1.280            | Casa        | 0,15          | 2            | 2     | 129.000      |
| 20 | 1.139            | Apartamento |               | 1            | 1     | 106.000      |

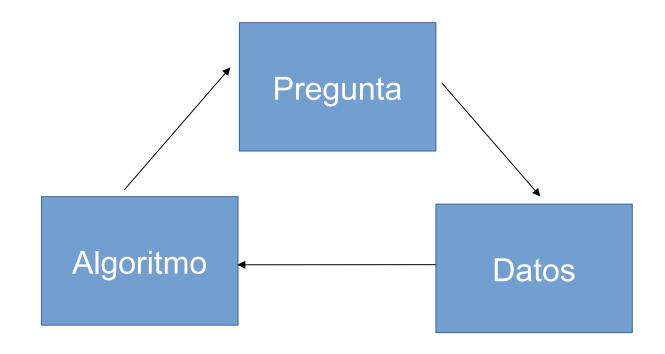


| id | superficie_sq_ft | tipo        | parcela_acres | habitaciones | banos | precio_venta |            |         |
|----|------------------|-------------|---------------|--------------|-------|--------------|------------|---------|
| 1  | 719              | Casa        | 1,64          | 1            | 1     | 88.000       |            |         |
| 2  | 2.017            | Apartamento |               | 3            | 2     | 164.000      |            |         |
| 3  | 697              | Apartamento |               | 1            | 1     | 72.000       |            |         |
| 4  | 948              | Casa        | 1,02          | 2            | 3     | 85.000       |            |         |
| 5  | 3.375            | Apartamento |               | 3            | 4     | 271.000      |            |         |
| 6  | 3.968            | Apartamento |               | 4            | 4     | 482.000      |            |         |
| 7  | 790              | Apartamento |               | 1            | 2     | 88.000       |            |         |
| 8  | 1.341            | Casa        | 0,66          | 3            | 3     | 128.000      |            |         |
| 9  | 2.379            | Apartamento |               | 3            | 3     | 235.000      |            |         |
| 10 | 2.495            | Casa        | 0,21          | 3            | 4     | 309.000      |            |         |
| 11 | 1.356            | Apartamento |               | 1            | 1     | 163.000      |            |         |
| 12 | 3.361            | Casa        | 1,64          | 3            | 4     | 375.000      |            |         |
| 13 | 1.060            | Casa        | 0,05          | 1            | 1     | 98.000       | Prediccion | Error   |
| 14 | 582              | Casa        | 0,61          | 1            | 1     | 50.000       | 41.000     | -9.000  |
| 15 | 1.640            | Apartamento |               | 2            | 3     | 145.000      | 165.000    | 20.000  |
| 16 | 3.546            | Casa        | 0,40          | 4            | 4     | 394.000      | 380.000    | -14.000 |
| 17 | 903              | Apartamento |               | 2            | 2     | 82.000       | 76.000     | -6.000  |
| 18 | 1.096            | Casa        | 0,40          | 3            | 4     | 105.000      | 128.000    | 23.000  |
| 19 | 1.280            | Casa        | 0,15          | 2            | 2     | 129.000      | 115.000    | -14.000 |
| 20 | 1.139            | Apartamento |               | 1            | 1     | 106.000      | 94.000     | -12.000 |



- Hay casas con mas baños que habitaciones
- División Casa / Apartamento
- Elementos vacíos, outliers (ELT)
- Nuevas columnas (feature engineering)
- Cross Validation
- Nuevos algoritmos
- De donde vienen los datos y, sobre todo: Cuenta de resultados







# Machine Learning automatizado

- Trifacta Wrangler (link)
- IBM Watson (link)
- Datarobot (link)
- Daitaku (link)
- Domino (link)
- Seldon (link)
- Alterix (link)
- H2O



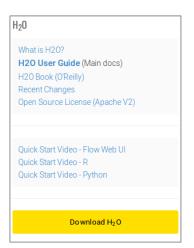
### **H20**

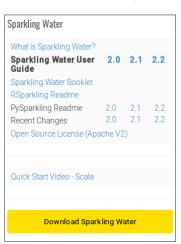
- Creada en 2011 (inicialmente 0xdata)
- Noviembre 2015: +\$20M (B) ya tenian \$14M
- Noviembre 2017: +\$40M (ℂ) Total \$75M. (Nvidia, Wells Fargo)
- Personas
- Kaggle

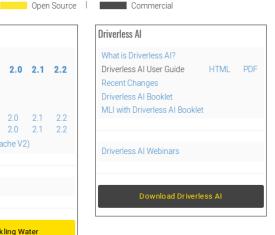


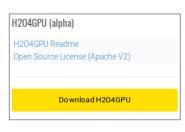
### Oferta de H2O

#### **Getting Started & User Guides**



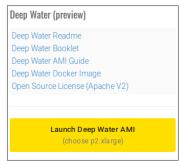












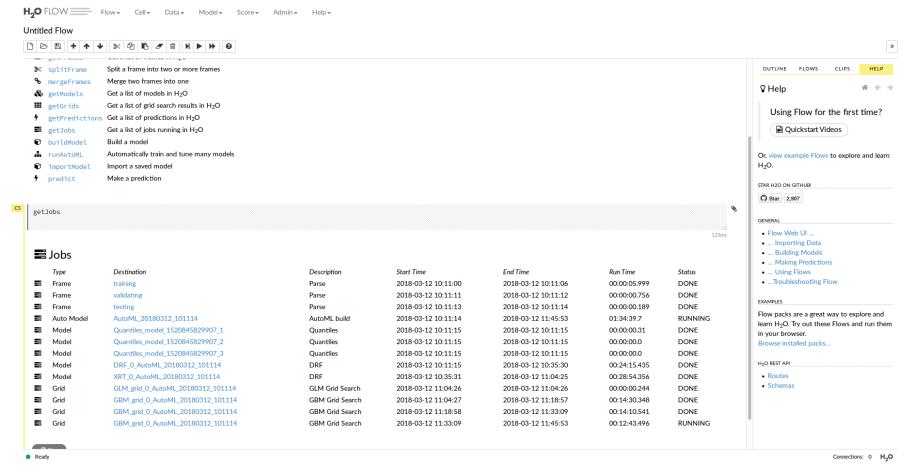
http://docs.h2o.ai/?\_ga=2.107667714.1485748875.1520325919-538902739.151211716

### **H20**

- Basada en java
- Facilidades para escalar
- Paralización. Para R, substituto data.table
- Maquina local, cluster o en cloud
- Funciona como API, pero tiene navegador
- Acceso desde R o Python
- Pagina (link), blog (link) y para iniciarse (link y link)



### Localhost H2O





## Instalación desde R

DOWNLOAD AND RUN

INSTALL IN R

INSTALL IN PYTHON

INSTALL ON HADOOP

USE FROM MAVEN

#### Use H<sub>2</sub>O directly from R

Copy and paste these commands into R one line at a time:

```
# The following two commands remove any previously installed H20 packages for R.
if ("package:h20" %in% search()) { detach("package:h20", unload=TRUE) }
if ("h20" %in% rownames(installed.packages())) { remove.packages("h20") }

# Next, we download packages that H20 depends on.
pkgs <- c("RCurl", "jsonlite")
for (pkg in pkgs) {
   if (! (pkg %in% rownames(installed.packages()))) { install.packages(pkg) }
}

# Now we download, install and initialize the H20 package for R.
install.packages("h20", type="source", repos="http://h20-release.s3.amazonaws.com/h20/rel-wolpert /4/R")

# Finally, let's load H20 and start up an H20 cluster
library(h20)
h20.init()</pre>
```



## Conectar dos servidores

#### 

#### NO DES

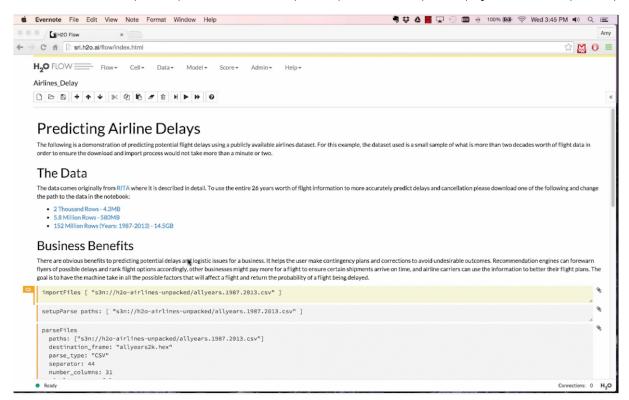
| Name                          | Ping              | Cores | Load  | My CPU % | Sys CPU % | <b>GFLOPS</b> | Memory Bandwidth | Data (Used/Total) | Data (% Cached) | GC (Free / Total / Max)             |
|-------------------------------|-------------------|-------|-------|----------|-----------|---------------|------------------|-------------------|-----------------|-------------------------------------|
| <pre>192.168.1.68:55555</pre> | a few seconds ago | 16    | 0.032 | -1       | -1        | 13.799        | 11.54 GB / s     | - / NaN undefined | NaN96           | 12.84 GB / NaN undefined / 13.33 GB |
| 192.168.1.148:55555           | a few seconds ago | 4     | 0.510 | -1       | -1        | 12.229        | 17.03 GB / s     | - / NaN undefined | NaN96           | 6.95 GB / NaN undefined / 6.97 GB   |
| ▼ TOTAL                       | -                 | 20    | 0.542 | -        | -         | 26.028        | 28.57 GB / s     | - / NaN undefined | NaN96           | 19.78 GB / NaN undefined / 20.30 GB |





### Analizar retrasos en vuelos con H2O

Video (link), en flow (link), en R (link) y datos (link)

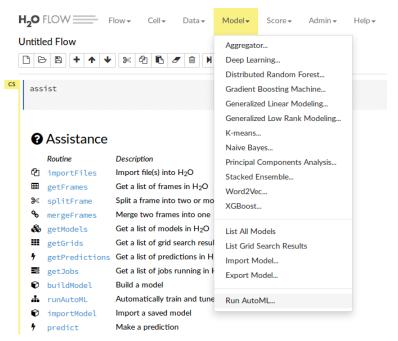


http://university.h2o.ai/data-science-101/lesson2.html



### **AutoML**

- Sólo hay que darle el dataset, target y tiempo
- Básicamente hace un stacking de modelos





# Demo. Crímenes en L.A.

- Basada en estos posts (link1 y link2)
- Con datos de opendata de Los Ángeles (link). Hay que bajarlos
- Los datos necesitan de tratamiento previo
- Necesitaría mas ETL y mas feature engineering
- Página de github (link)



# **DriverlessAl**

- Licencia
- Coste (precio anual + equipos)
- Docker
- Vídeo



# DriverlessAI. Requerimientos

- 64G de RAM
- GPU con CUDA (Pascal o Volta)
- Docker (o Nvidia docker)
- Cloud, Server, Desktop
- Linux, Mac, Windows 10



### **DriverlessAl**



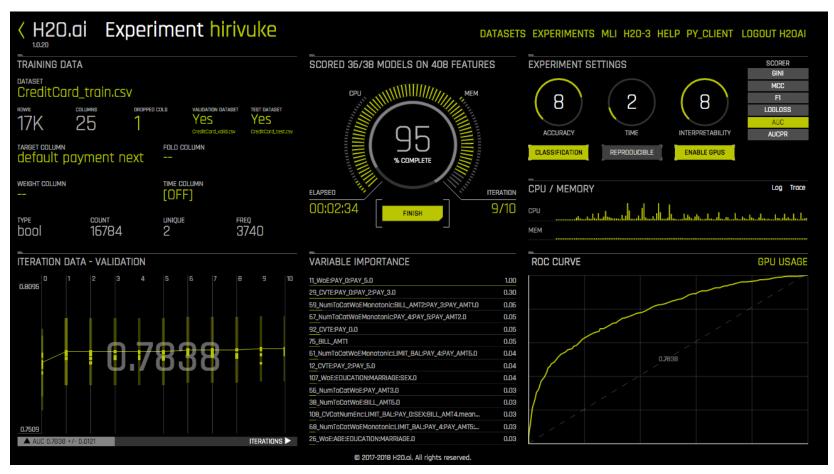


# DriverlessAl. Parámetros

- Speed
- Accuracy
- Interpretability
- Train / [Test] / [Validation]
- Target
- Scorer



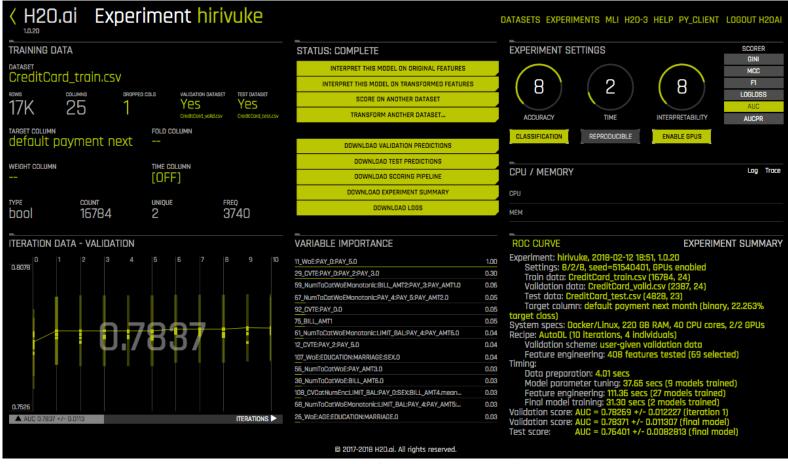
## **DriverlessAl**







## **DriverlessAl**



https://www.youtube.com/watch?time\_continue=43&v=KkvWX3FD7y



# DriverlessAI. Prueba en Kaggle Favorita

- Concurso Kaggle Favorita (link)
- Estación de trabajo Z800. 16 cores. 24G RAM sin GPU
- Posición final: 126 de 1675 (medalla de bronce)
- Métrica: Normalized Weighted Root Mean Squared Logarithmic Error
- Mis mejores resultados: 0,520 (combinado) y 0,521 con un modelo LGBM.
- Resultado del ganador: 0,509
- Mejor resultado DriverlessAI: 1,240 (posición 1.131)

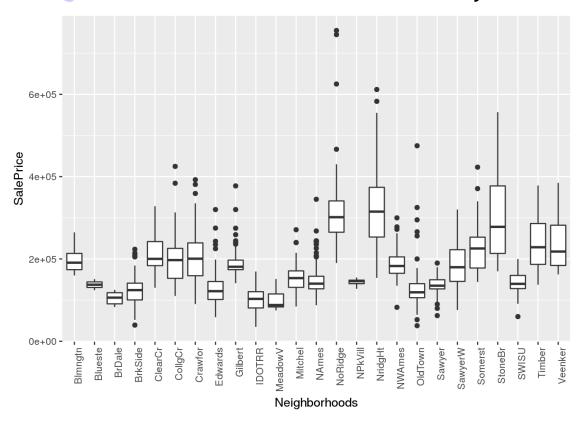


# Una solución: Pred028. 1,264. 1:20:00



# Concurso precios de alquileres (Kaggle)

Página del concurso. Tutoriales. Kernels y Foro





### Conclusiones

- En muy poco tiempo (¿este año?) vamos a tener herramientas comerciales de Machine Learning Automatizado como DriverlessAl
- Inicialmente su uso tendrá sentido en determinados escenarios
- La herramienta H2O (gratuita) tiene mucho sentido, por su capacidad de escalar, sus distintas interfaces y sus posibilidades de paralelización
- AutoML tiene aún mucho camino que recorrer



### **GRACIAS**

Datos de contacto:

Santiago Mota Herce

E-mail: santiago\_mota@yahoo.es

Github: https://github.com/santiagomota

LinkedIn: https://es.linkedin.com/in/santiagomota

