# Grupo de R Madrid (10/05/2018) Machine Learning Automatizado

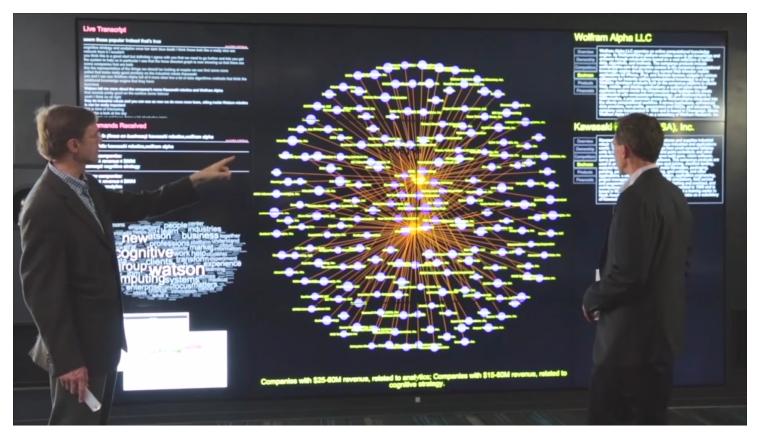


## Presentación

- Físico. MBA y Máster Bl y BigData
- Consultor Freelance
- Kaggle Máster
- Socio Asociación de Usuarios de R de España
- santiago\_mota@yahoo.es
- http://es.linkedin.com/in/santiagomota



# Dario Gil: Cognitive systems and the future of expertise TED (22/12/2014)





# IBM anuncia Watson Analytics, un servicio de analítica cognitiva de negocio (19/09/2014)

- "IBM Watson Analytics automatiza, además, algunos pasos del análisis, como la preparación de los datos, el análisis predictivo y la visualización... ".
- "Diálogo en lenguaje natural: el nuevo producto entiende el lenguaje natural, por lo que solo es necesario teclear lo que al usuario le gustaría ver...".
- "Analítica predictiva "guiada": el servicio es capaz de guiar al usuario en patrones y resultados de los datos en los que el usuario tradicionalmente no se fijaría".

# Gartner. Data Science y ML Platforms







# Tools that Data Scientists actually use



id	superficie_sq_ft	tipo	parcela_acres	habitaciones	banos	precio_venta
1	719	Casa	1,64	1	1	88.000
2	2.017	Apartamento	,	3	2	164.000
3	697	Apartamento		1	1	72.000
4	948	Casa	1,02	2	3	85.000
5	3.375	Apartamento		3	4	271.000
6	3.968	Apartamento		4	4	482.000
7	790	Apartamento		1	2	88.000
8	1.341	Casa	0,66	3	3	128.000
9	2.379	Apartamento		3	3	235.000
10	2.495	Casa	0,21	3	4	309.000
11	1.356	Apartamento		1	1	163.000
12	3.361	Casa	1,64	3	4	375.000
13	1.060	Casa	0,05	1	1	98.000
14	582	Casa	0,61	1	1	50.000
15	1.640	Apartamento		2	3	145.000
16	3.546	Casa	0,40	4	4	394.000
17	903	Apartamento		2	2	82.000
18	1.096	Casa	0,40	3	4	105.000
19	1.280	Casa	0,15	2	2	129.000
20	1.139	Apartamento		1	1	106.000

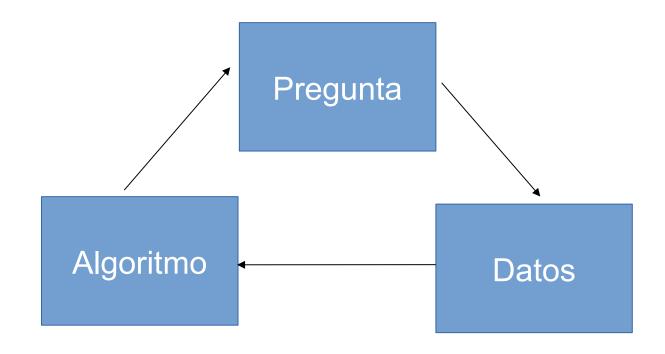


id	superficie_sq_ft	tipo	parcela_acres	habitaciones	banos	precio_venta		
1	719	Casa	1,64	1	1	88.000		
2	2.017	Apartamento		3	2	164.000		
3	697	Apartamento		1	1	72.000		
4	948	Casa	1,02	2	3	85.000		
5	3.375	Apartamento		3	4	271.000		
6	3.968	Apartamento		4	4	482.000		
7	790	Apartamento		1	2	88.000		
8	1.341	Casa	0,66	3	3	128.000		
9	2.379	Apartamento		3	3	235.000		
10	2.495	Casa	0,21	3	4	309.000		
11	1.356	Apartamento		1	1	163.000		
12	3.361	Casa	1,64	3	4	375.000		
13	1.060	Casa	0,05	1	1	98.000	Prediccion	Error
14	582	Casa	0,61	1	1	50.000	41.000	-9.000
15	1.640	Apartamento		2	3	145.000	165.000	20.000
16	3.546	Casa	0,40	4	4	394.000	380.000	-14.000
17	903	Apartamento		2	2	82.000	76.000	-6.000
18	1.096	Casa	0,40	3	4	105.000	128.000	23.000
19	1.280	Casa	0,15	2	2	129.000	115.000	-14.000
20	1.139	Apartamento		1	1	106.000	94.000	-12.000



- Hay casas con mas baños que habitaciones
- División Casa / Apartamento
- Elementos vacíos, outliers (ELT)
- Nuevas columnas (feature engineering)
- Cross Validation
- Nuevos algoritmos
- De donde vienen los datos y, sobre todo: Cuenta de resultados







# Machine Learning automatizado

- Trifacta Wrangler (link)
- IBM Watson (link)
- Datarobot (link)
- Daitaku (link)
- Domino (link)
- Seldon (link)
- Alterix (link)
- H2O



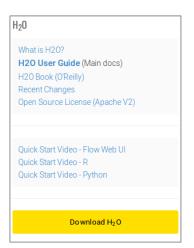
### **H20**

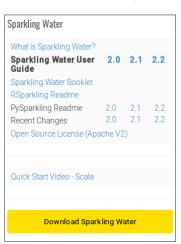
- Creada en 2011 (inicialmente 0xdata)
- Noviembre 2015: +\$20M (B) ya tenian \$14M
- Noviembre 2017: +\$40M (ℂ) Total \$75M. (Nvidia, Wells Fargo)
- Personas
- Kaggle

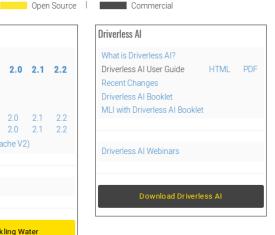


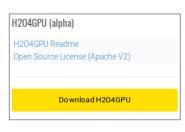
### Oferta de H2O

#### **Getting Started & User Guides**



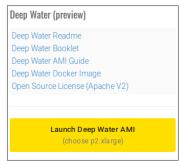












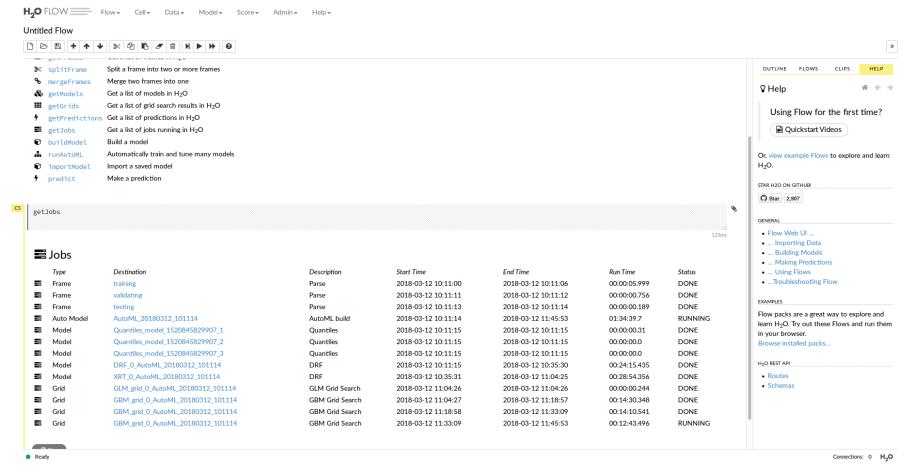
http://docs.h2o.ai/?\_ga=2.107667714.1485748875.1520325919-538902739.151211716

### **H20**

- Basada en java
- Facilidades para escalar
- Paralización. Para R, substituto data.table
- Maquina local, cluster o en cloud
- Funciona como API, pero tiene navegador
- Acceso desde R o Python
- Pagina (link), blog (link) y para iniciarse (link y link)



### Localhost H2O





## Instalación desde R

DOWNLOAD AND RUN

INSTALL IN R

INSTALL IN PYTHON

INSTALL ON HADOOP

USE FROM MAVEN

#### Use H<sub>2</sub>O directly from R

Copy and paste these commands into R one line at a time:

```
# The following two commands remove any previously installed H20 packages for R.
if ("package:h20" %in% search()) { detach("package:h20", unload=TRUE) }
if ("h20" %in% rownames(installed.packages())) { remove.packages("h20") }

# Next, we download packages that H20 depends on.
pkgs <- c("RCurl", "jsonlite")
for (pkg in pkgs) {
   if (! (pkg %in% rownames(installed.packages()))) { install.packages(pkg) }
}

# Now we download, install and initialize the H20 package for R.
install.packages("h20", type="source", repos="http://h20-release.s3.amazonaws.com/h20/rel-wolpert /4/R")

# Finally, let's load H20 and start up an H20 cluster
library(h20)
h20.init()</pre>
```



## Conectar dos servidores

#### 

#### NODE5

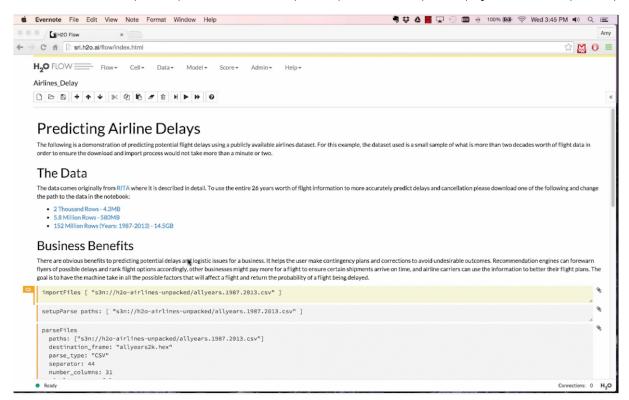
Name	Ping	Cores	Load	My CPU %	Sys CPU %	<b>GFLOPS</b>	Memory Bandwidth	Data (Used/Total)	Data (% Cached)	GC (Free / Total / Max)
<pre>192.168.1.68:55555</pre>	a few seconds ago	16	0.032	-1	-1	13.799	11.54 GB / s	- / NaN undefined	NaN96	12.84 GB / NaN undefined / 13.33 GB
192.168.1.148:55555	a few seconds ago	4	0.510	-1	-1	12.229	17.03 GB / s	- / NaN undefined	NaN96	6.95 GB / NaN undefined / 6.97 GB
▼ TOTAL	-	20	0.542	-	-	26.028	28.57 GB / s	- / NaN undefined	NaN96	19.78 GB / NaN undefined / 20.30 GB





### Analizar retrasos en vuelos con H2O

Video (link), en flow (link), en R (link) y datos (link)

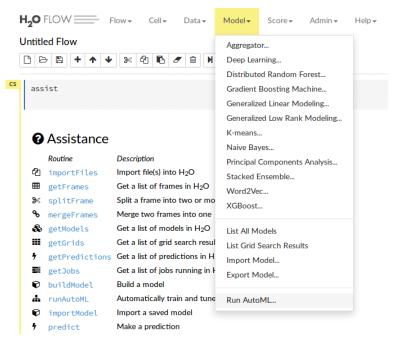


http://university.h2o.ai/data-science-101/lesson2.html



### **AutoML**

- Sólo hay que darle el dataset, target y tiempo
- Básicamente hace un stacking de modelos





# Demo. Crímenes en L.A.

- Basada en estos posts (link1 y link2)
- Con datos de opendata de Los Ángeles (link). Hay que bajarlos
- Los datos necesitan de tratamiento previo
- Necesitaría mas ETL y mas feature engineering
- Página de github (link)



# **DriverlessAl**

- Licencia
- Coste (precio anual + equipos)
- Docker
- Vídeo



# DriverlessAI. Requerimientos

- 64G de RAM
- GPU con CUDA (Pascal o Volta)
- Docker (o Nvidia docker)
- Cloud, Server, Desktop
- Linux, Mac, Windows 10
- Licencia (ahora 21 días)
- Documentación



### **DriverlessAl**



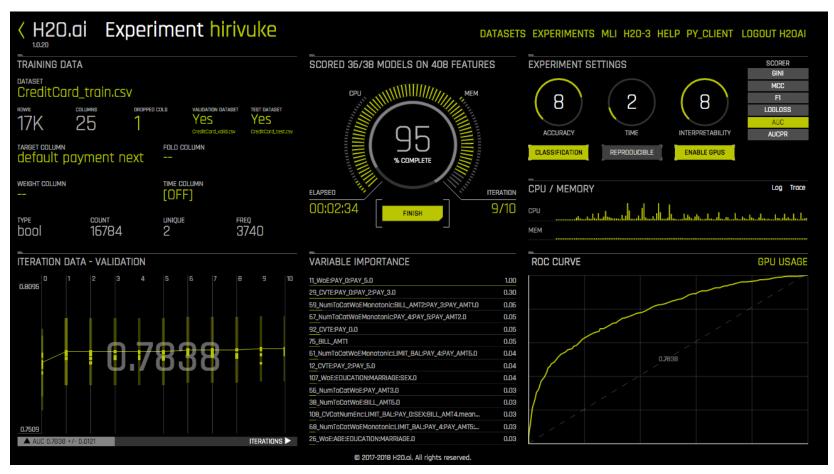


# DriverlessAl. Parámetros

- Speed
- Accuracy
- Interpretability
- Train / [Test] / [Validation]
- Target
- Scorer



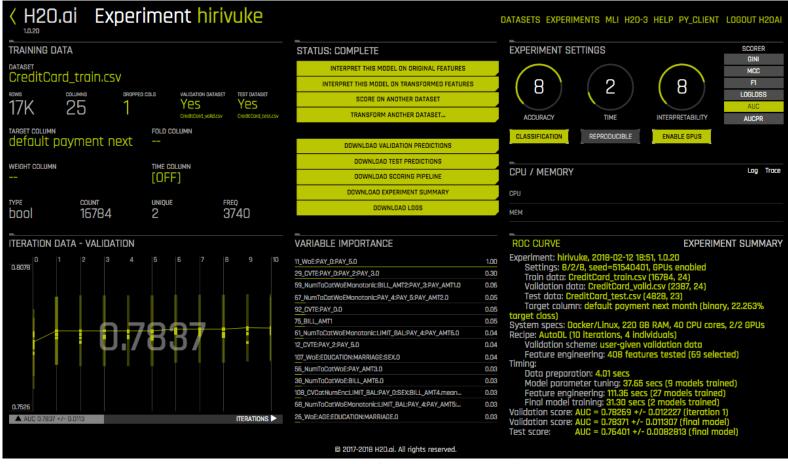
## **DriverlessAl**







## **DriverlessAl**



https://www.youtube.com/watch?time\_continue=43&v=KkvWX3FD7y



# DriverlessAI. Prueba en Kaggle Favorita

- Concurso Kaggle Favorita (link)
- Estación de trabajo Z800. 16 cores. 24G RAM sin GPU
- Posición final: 126 de 1675 (medalla de bronce)
- Métrica: Normalized Weighted Root Mean Squared Logarithmic Error
- Mis mejores resultados: 0,520 (combinado) y 0,521 con un modelo LGBM.
- Resultado del ganador: 0,509
- Mejor resultado DriverlessAI: 1,240 (posición 1.131)



# Una solución: Pred028. 1,264. 1:20:00



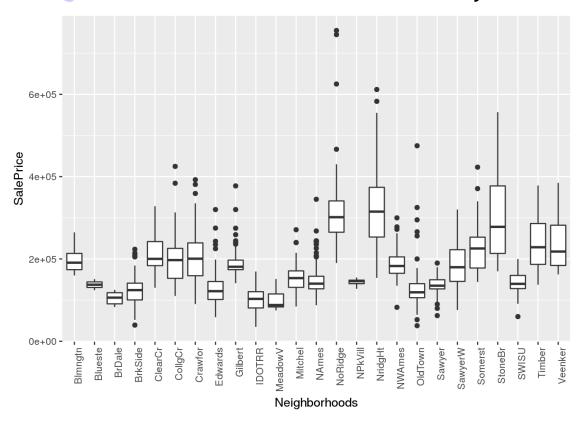
# DriverlessAI. Prueba en Kaggle Avito

- Concurso Kaggle Avito (link)
- Es un concurso de imágenes
- Estación de trabajo Z800. 16 cores. 60G RAM sin GPU
- Métrica: RMSE
- Baseline (link) un xgboost en torno a 0,2247
- El mejor actual 0,2190



# Concurso precios de alquileres (Kaggle)

Página del concurso. Tutoriales. Kernels y Foro





### **Conclusiones**

- En muy poco tiempo (¿este año?) vamos a tener herramientas comerciales de Machine Learning Automatizado como DriverlessAl
- Inicialmente su uso tendrá sentido en determinados escenarios
- La herramienta H2O (gratuita) tiene mucho sentido, por su capacidad de escalar, sus distintas interfaces y sus posibilidades de paralelización
- AutoML tiene aún mucho camino que recorrer
- ¿A quien va dirigido?
- Los datos en un csv



### **GRACIAS**

Datos de contacto:

Santiago Mota Herce

E-mail: santiago\_mota@yahoo.es

Github: https://github.com/santiagomota

LinkedIn: https://es.linkedin.com/in/santiagomota

